



Московский государственный университет имени М.В.Ломоносова
Факультет вычислительной математики и кибернетики
Кафедра суперкомпьютеров и квантовой информатики

Акопян Микаэла Тиграновна

**Разработка предиктивных алгоритмов для
анализа публикационной активности в области
высокопроизводительных вычислений**

Выпускная квалификационная работа

Группа 423

Научный руководитель:

к.т.н.

Григорьева Мария Александровна

Москва, 2026

Содержание

1	Введение	3
2	Формальная постановка цели ВКР	5
3	Задачи, выполнение которых необходимо для достижения цели ВКР	7
4	Сбор данных	8
4.1	Выбор подходящего ресурса	8
4.2	Извлечение информации	8
5	Выбор подходящей модели представления научных текстов	10
6	Архитектура и адаптация модели представлений	12
6.1	Архитектура оригинальной модели SPECTER	12
6.2	Добавление графа связей публикаций на основании авторства	13
6.3	Итоговая схема предлагаемого подхода модели представлений	14
7	Методика оценки качества представлений	16
8	Архитектура нейросетевой модели рекомендаций	18
9	Практические результаты	19
9.1	Обзор программной реализации	19
9.2	Практическая реализация сбора данных	20
9.3	Обучение модели SPECTER	28
9.4	Оценка качества векторных представлений	30
9.5	Работа рекомендательной модели	33
10	Заключение	36
11	Литература	38
12	Приложение 1	39
13	Приложение 2	40

1 Введение

В последние годы область высокопроизводительных вычислений (High Performance Computing, HPC) значительно расширила своё влияние. Цель ВКР — изучить структуру публикационной активности в области HPC и создать основу для рекомендательной системы, помогающей выбирать оптимальные условия для размещения научных результатов. В рамках её достижения был проведён количественный анализ публикаций за последние 25 лет. Он подтвердил устойчивое повышение интереса к данной теме.

Во многом рост числа статей связан с развитием методов машинного и глубокого обучения, требующих больших вычислительных мощностей. Эта тенденция хорошо прослеживается на примере публикационной активности в онлайн-библиотеке научных статей arXiv.org. По тегам *high performance computing*, *supercomputer*, *parallel computing*: если в начале XXI века публиковалось 100–200 статей в год, то в ещё не завершённом на момент сбора 2025 году их число превысило десять тысяч. Аккумуляированные по годам результаты представлены на рис. 1.




Рис. 1: Количество публикаций в онлайн-библиотеке arXiv.org по запросу *high performance computing*, *supercomputer*, *parallel computing*

Важно понимать, что каждая статья существует не изолировано, а является частью более широкого научного контекста. Однако стремительный рост числа публикаций по тематике высокопроизводительных вычислений затруднил изучение динамики развития области без применения специализированных средств программного анализа дан-

ных. Это усложняет поиск релевантных работ и принятие оптимальных решений при выборе соавторов, исследовательских организаций, площадок для публикации и других параметров метаданных.

В рамках поставленной цели особое внимание уделяется характеристикам, связанным с параметрами публикации научных результатов. Под параметрами в данной работе понимаются такие характеристики, как выбор релевантной научной площадки (журнала или конференции), определение наиболее подходящего тематического направления, а также анализ и предложение авторских коллективов и организаций, ведущих исследования в схожих областях. Разработка такой системы позволит автоматизировать процесс ориентирования в быстро растущем массиве публикаций и упростить исследователю принятие решений о стратегии публикации.

2 Формальная постановка цели ВКР

Пусть задана предобученная модель представления научных текстов в векторном пространстве:

$$f : S \rightarrow \mathbb{R}^d,$$

где S — пространство научных текстов, а $\mathbb{R}^k$ — пространство эмбедингов фиксированной размерности.

Рассматривается специализированный корпус научных публикаций в области высокопроизводительных вычислений:

$$D = \{d_1, d_2, \dots, d_n\},$$

где каждая публикация описывается набором признаков:

$$d_i = (t_i, a_i, c_i, v_i),$$

где:

- t_i — название публикации,
- a_i — аннотация,
- c_i — информация об авторах,
- v_i — площадка публикации.

Требуется адаптировать модель f к специализированному корпусу D для повышения качества семантического представления публикаций в предметной области НРС.

Пусть пользовательский запрос задаётся как X_q — текстовое описание исследования.

Необходимо определить функцию ранжирования:

$$R : \mathbb{R}^d \times D \rightarrow \mathbb{R},$$

Для заданного запроса требуется сформировать два ранжированных множества рекомендаций:

$$f_{\text{papers}}(X_q),$$

— список релевантных научных публикаций;

$$f_{\text{venue}}(X_q),$$

— список рекомендуемых площадок публикации.

Итоговая выборка релевантных публикаций определяется как:

$$Top-k(q) = \arg \max_{d_i \in D} R(f(X_q), f(d_i)).$$

3 Задачи, выполнение которых необходимо для достижения цели ВКР

Для достижения поставленной цели в работе решаются следующие задачи:

1. Провести анализ существующих моделей представления научных текстов и методов построения рекомендательных систем для научных публикаций.
2. Выявить ограничения существующих подходов и предложить способ повышения качества семантических представлений и рекомендаций публикаций.
3. Сформировать специализированный корпус научных публикаций в области высокопроизводительных вычислений.
4. Адаптировать предобученную модель эмбедингов научных текстов к специализированному корпусу публикаций в области НРС и реализовать предложенные модификации.
5. Выполнить дообучение модели эмбедингов научных текстов на сформированном корпусе публикаций.
6. Разработать и реализовать модель ранжирования публикаций на основе полученных векторных представлений.
7. Провести экспериментальную оценку качества предложенного подхода с использованием объективных метрик.

4 Сбор данных

4.1 Выбор подходящего ресурса

Одним из наиболее известных и богатых по содержанию источников современных научных публикаций по тематике высокопроизводительных вычислений является онлайн-библиотека arXiv.org¹. Платформа содержит большое количество актуальных научных работ, активно используется исследовательским сообществом. Однако при всей своей масштабности ресурс обладает существенными ограничениями: в нём нет структурированной информации о цитируемости, месте публикации и ряде других ключевых метаданных.

Существуют альтернативные платформы, Semantic Scholar² и OpenAlex³, которые предоставляют значительно более полную статистику публикаций. Но у этих ресурсов есть и свои недостатки: прежде всего, скудная система тематических меток. И OpenAlex, и Semantic Scholar опираются на заранее подготовленные категории, которые описывают содержание работ только лишь в общих чертах.

В отличие от этого, на arXiv каждая статья сопровождается не только категорией, но и набором ключевых слов, указанных авторами. Эти ключевые слова обычно отражают методы, подходы, технические детали и конкретную проблематику исследования. Именно это делает поиск по arXiv значительно более точным и продуктивным.

С учётом описанной неоднозначности было принято решение объединить их сильные стороны: использовать точный тематический поиск по ключевым словам на arXiv.org, а статистику цитируемости, данные о конференциях и другие библиографические характеристики получать из Semantic Scholar и OpenAlex.

4.2 Извлечение информации

Для формирования корпуса публикаций решено использовать программную выгрузку данных из выбранных источников. Сначала по тематическим ключевым словам (см. приложение 1) получен набор работ, относящихся к области высокопроизводительных вычислений. Затем для найденных публикаций собраны дополнительные библиографи-

¹<https://arxiv.org>

²<https://www.semanticscholar.org>

³<https://openalex.org>

ческие характеристики: сведения об авторах, цитируемости, площадках публикации и тематических тегах.

В качестве связующего идентификатора предполагается использовать DOI, позволяющий сопоставлять одну и ту же публикацию между различными источниками данных. На этапе реализации планируется получить следующие поля: название, авторы, ключевые слова, дата публикации, DOI, число цитирований, место и тип публикации, теги в OpenAlex (поле, подполе, тематическое направление ООН⁴).

Полученный корпус далее использован для статистического анализа публикационной активности и построения графов связей между публикациями.

⁴Под тематическим направлением ООН подразумевается отнесение статьи к одной из глобальных Целей устойчивого развития (SDG), используемых Организацией Объединённых Наций для классификации исследований по тематическим областям.

5 Выбор подходящей модели представления научных текстов

На основе изученной литературы и практической доступности инструментов выделяются два наиболее перспективных подхода — SciBERT⁵ и SPECTER⁶. Использование моделей SciBERT и SPECTER необходимо для решения основной задачи работы — построения рекомендательной системы, способной анализировать содержимое научных текстов и определять их тематическую близость. Эти модели позволяют получать качественные семантические представления (эмбединги) публикаций, что впоследствии используется для выбора релевантных научных площадок, выявления близких работ и анализа структуры исследовательских направлений в области НРС. Для оценки их характеристик были проведены тестовые эксперименты, а также выполнено сравнение с классическим BERT⁷, выступающим в роли базовой модели.

Эксперимент был построен следующим образом: были подготовлены по 5 крупных текстовых фрагментов, относящихся к областям биологии, химии и математики. Для каждого текста вычислялись эмбединги моделей, после чего проводилось сравнение косинусного сходства между ними и эмбедингами заранее определённых тематических описаний. Такой подход позволил получить приближённую оценку "уверенности" моделей в принадлежности текста к определённой научной области, а также сравнить качество семантического представления текстов разными архитектурами.

Model	Biology	Chemistry	Mathematics
BERT	0.3628	0.3609	0.3337
SciBERT	0.5107	0.4313	0.3954
SPECTER	0.7047	0.5977	0.5930

Таблица 1: Пример результатов трёх моделей для текста о строении клеток организма

BERT демонстрирует почти равные значения для всех трёх тем, что подтверждает: стандартный BERT не специализируется на научной терминологии и плохо отделяет домены.

⁵<https://github.com/allenai/scibert>

⁶<https://github.com/allenai/specter>

⁷<https://github.com/google-research/bert>

SciBERT показывает максимальную близость текста к биологии (0.5107), что соответствует ожиданиям, ведь модель обучена на научных текстах и уверенно различает биологический контекст.

SPECTER даёт наибольшие абсолютные значения сходства по всем темам и наиболее уверенное приближение к биологии (0.7047). Это согласуется с тем, что SPECTER обучен на корпусе научных статей и оптимизирован для понимания научного содержания на уровне документов.

В силу своей точности именно SPECTER выбрана как baseline-модель для проведения дальнейших экспериментов.

6 Архитектура и адаптация модели представлений

6.1 Архитектура оригинальной модели SPECTER

Основная идея модели SPECTER состоит в использовании не только текстового содержания статьи, но и структуры графа цитирования как источника информации о семантической близости публикаций.

Архитектурно SPECTER основана на трансформерной модели SciBERT, предобученной на корпусе научных текстов. На вход модели подаётся конкатенация названия и аннотации научной публикации:

$$x_i = [t_i; a_i],$$

где t_i — название статьи, а a_i — её аннотация.

Обучение SPECTER выполняется с использованием триплетов публикаций:

$$(d_q, d^+, d^-),$$

где d_q — исходная публикация, d^+ — близкая публикация, связанная с ней цитированием, а d^- — далёкая публикация, не связанная с исходной публикацией напрямую.

Для формирования положительных и отрицательных примеров используется граф цитирования. Если две статьи соединены ребром цитирования, они рассматриваются как семантически близкие. Статьи, не имеющие прямой связи с исходной публикацией, используются как отрицательные примеры.

Цель обучения состоит в том, чтобы расстояние между эмбедингами связанных публикаций было меньше, чем расстояние между несвязанными публикациями. Для этого используется triplet loss:

$$\mathcal{L} = \max(d(z_q, z^+) - d(z_q, z^-) + m, 0),$$

где z_q — эмбединг исходной публикации, z^+ — эмбединг близкой публикации, z^- — эмбединг далёкой публикации, $d(\cdot, \cdot)$ — функция расстояния между эмбедингами, а m — заданный отступ.




Рис. 2: Схематичное представление обучения модели

6.2 Добавление графа связей публикаций на основании авторства

В оригинальной модели SPECTER обучающие примеры формируются на основе графа цитирования. В таком графе вершинами являются публикации, а направленные рёбра соответствуют фактам цитирования одной статьи другой. Если две публикации связаны прямым ребром цитирования, они рассматриваются как близкие, поскольку между ними предполагается содержательная или тематическая связь. Публикации, которые не имеют прямой связи в графе цитирования, могут использоваться как отрицательные примеры.

Однако для корпуса публикаций в области высокопроизводительных вычислений одного графа цитирования недостаточно для полного описания связей между работами. Две статьи могут быть тематически близкими не только из-за прямого цитирования, но и из-за принадлежности к одной исследовательской группе, одному автору или устойчивому коллективу соавторов. Поэтому в данной работе исходный подход был расширен за счёт дополнительного графа, построенного на основании информации об авторах публикаций.

В предложенном графе вершинами также являются публикации, однако связи между ними определяются через авторские отношения. Если две статьи имеют общего автора, они рассматриваются как близкие, поскольку с высокой вероятностью относятся к одной научной области или продолжают одно исследовательское направление. Если статьи не имеют общего автора, но связаны через одну промежуточную вершину, такая

связь рассматривается как далёкая.

Таким образом, дополнительный граф авторства позволяет учитывать не только явные связи между статьями, задаваемые цитированием, но и скрытые связи, возникающие из структуры научного сотрудничества. Это расширяет набор обучающих сигналов для модели: положительные примеры могут формироваться не только по цитатным связям, но и по общим авторам, а связи через одну промежуточную вершину могут использоваться как далёкие примеры. Такое разделение близких и более слабых связей повышает тонкость семантического распознавания: модель обучается отличать явно связанные публикации от работ, находящихся в смежном, но менее тесном исследовательском контексте.




Рис. 3: Графовое представление связей между публикациями

6.3 Итоговая схема предлагаемого подхода модели представлений

Итоговый процесс адаптации модели состоит из нескольких последовательных этапов. На первом этапе из собранного корпуса публикаций выделяются текстовые данные, сведения о цитированиях и информация об авторах. На основании этих данных строятся два графа: граф цитирования и граф авторства. Модель SPECTER дообучается сначала с использованием графа цитирования. После этого выполняется дополнительное дообучение на графе авторства.




Рис. 4: Последовательность адаптации модели на графах цитирования и авторства

Таким образом, граф цитирования используется как основной источник информации, соответствующий оригинальной идее обучения SPECTER, а граф авторства применяется на следующем этапе для уточнения представлений публикаций. Такая последовательность позволяет сначала сохранить семантические связи, полученные с помощью анализа цитирования, а затем дополнить их связями, отражающими авторские коллективы и научное сотрудничество.

7 Методика оценки качества представлений

Для оценки качества получаемых векторных представлений используется набор задач и метрик из SciRepEval⁸. Этот бенчмарк использовался авторами оригинальной статьи SPECTER предназначен для обучения и оценки моделей представления научных документов. В него входят задачи классификации, ранжирования, поиска и оценки близости публикаций.

В качестве базового варианта рассматривается модель, дообученная на графе цитирования (CG, citation graph). С ней предлагается сравнивать модель, в которой дополнительно используется граф авторства (CG + AG, citation graph + author graph). Также каждая из конфигураций модели оценивается на оригинальном датасете и дополнительном собранном датасете HPC.

Качество представлений оценивается с использованием нескольких групп метрик:

- **F1** — гармоническое среднее точности и полноты. Метрика используется для оценки качества классификации публикаций по различным тематическим категориям: MAG отвечает за Microsoft Academic Graph, MeSH — классификация по медицинским предметным рубрикам.
- **MAP** (Mean Average Precision) — средняя точность ранжирования по всем запросам. Метрика показывает, насколько высоко в выдаче расположены релевантные публикации.
- **NDCG** (Normalized Discounted Cumulative Gain) — нормированная метрика качества ранжирования, учитывающая не только наличие релевантных объектов, но и их позиции в списке. Чем выше релевантная публикация находится в выдаче, тем больше вклад в значение метрики.
- **P@1** (Precision at 1) — точность на первой позиции. Метрика показывает, является ли наиболее высоко ранжированная рекомендация релевантной.

Метрики Co-view и Co-read относятся к восстановлению пользовательской активности: в первом случае близкими считаются статьи, просмотренные в одной сессии, во втором — статьи, PDF которых пользователь открывал для чтения. Метрики Cite и Co-cite относятся к предсказанию цитатных связей: Cite оценивает ранжирование прямо

⁸<https://github.com/allenai/scirepeval>

цитируемых работ, а Co-cite — работ, которые часто цитируются совместно. Для рекомендательной задачи используются скорректированные по позиционному смещению метрики $\widehat{NDCG}$ и $\widehat{P@1}$.

Для специализированного корпуса НРС используется сокращённый набор метрик. Метрики Co-view, Co-read и Co-cite не вычисляются, поскольку для них требуются дополнительные данные: пользовательские сессии просмотров и чтения статей. Эти данные размечены лишь для оригинального датасета.

Следует отметить, что итоговый вывод нейросетевой модели для конкретного пользователя или конкретной публикации не всегда может быть автоматически оценён с помощью объективной численной метрики. Для такой оценки необходима экспертная разметка: например, заранее известный набор релевантных площадок, потенциальных соавторов или тематически близких работ. В рамках данной работы такая экспертная разметка отсутствует, поэтому финальный вывод модели дополнительно проверяется качественно: анализируется, является ли он семантически согласованным с тематикой исходной публикации и не противоречит ли структуре найденных текстовых, цитатных и авторских связей.

8 Архитектура нейросетевой модели рекомендаций

Рекомендательная модель строится поверх векторных представлений научных публикаций. На этапе инференса для новой статьи используются только название и аннотация: по ним формируется эмбединг публикации, после чего статья сравнивается с публикациями из корпуса.

Для пары “статья-запрос – статья-кандидат” вычисляется вектор из пяти необучаемых признаков близости:

$$x(q, c) = [\cos(z_q, z_c), \|z_q - z_c\|_2, \|z_q - z_c\|_1, J(T_q, T_c), J(A_q, A_c)] ,$$

где z_q и z_c — эмбединги статьи-запроса и статьи-кандидата, T_q и T_c — множества токенов их названий, A_q и A_c — множества токенов их аннотаций. Первые три признака описывают близость публикаций в пространстве эмбедингов, а два последних позволяют дополнительно учитывать прямое совпадение терминов в названии и аннотации.

Ясскард-сходство для двух множеств токенов определяется как:

$$J(X, Y) = \frac{|X \cap Y|}{|X \cup Y|}.$$

Итоговая оценка релевантности кандидата вычисляется на основе этих признаков:

$$score(q, c) = F(x(q, c)).$$

В качестве функции F используется небольшая полносвязная сеть ранжирования:

$$x \in \mathbb{R}^5 \rightarrow \text{Linear}(5, 50) \rightarrow \text{ReLU} \rightarrow \text{Dropout}(0.4) \rightarrow \text{Linear}(50, 1) \rightarrow \text{Sigmoid} \rightarrow score.$$

При этом сами входные признаки получены непосредственно из названия, аннотации и эмбедингов публикаций. Это позволяет применять модель к новой статье без наличия дополнительных метаданных.

Итоговый список рекомендаций формируется сортировкой публикаций-кандидатов по убыванию значения $score(q, c)$.

9 Практические результаты

9.1 Обзор программной реализации

Практическая часть работы включает полный цикл построения рекомендательной системы: сбор корпуса научных публикаций, получение и обработку метаданных, построение эмбедингов, обучение модели представлений и последующее ранжирование релевантных публикаций и научных площадок. Основная реализация выполнена на Python с использованием библиотек PyTorch и AllenNLP для обучения нейросетевых моделей. Для работы с трансформерными архитектурами и моделями семейства BERT, SciBERT и SPECTER использовалась библиотека transformers.

Табличные данные и промежуточные результаты хранятся в форматах CSV и JSON, а для их обработки применяется библиотека pandas. Загрузка библиографических метаданных из OpenAlex реализована асинхронно с использованием aiohttp и asyncio, что позволяет обрабатывать большой объём запросов и постепенно формировать корпус публикаций по выбранной предметной области. Реализованный подход поддерживает обучение и инференс как на GPU, так и на CPU, поэтому может использоваться как на локальной машине, так и на вычислительном сервере.




Рис. 5: Общая схема программной реализации рекомендательной системы

Таким образом, входом системы является корпус публикаций в выбранной области и описание новой статьи. На основе корпуса формируются векторные представления, после чего модуль ранжирования упорядочивает публикации по близости их эмбедингов. Дополнительно по наиболее похожим публикациям определяются профильные площадки, которые могут быть использованы как ориентиры для дальнейшего поиска литературы или выбора места публикации.

9.2 Практическая реализация сбора данных

В ходе практической реализации был выполнен автоматизированный сбор корпуса научных публикаций по тематике высокопроизводительных вычислений. Для этого использовались API выбранных источников данных и их реализации в виде Python-библиотек. По набору тематических ключевых слов был разработан программный код, позволивший получить около 290 тысяч статей, опубликованных за последние 25 лет.

На первом этапе предполагалось использовать Semantic Scholar как источник расширенных библиографических метаданных. Однако при работе с данным ресурсом возникло ограничение: для полноценной загрузки требовался ключ доступа, который не был предоставлен авторами проекта. В связи с этим основным источником метаданных был выбран OpenAlex.

OpenAlex по объёму и ширине охвата информации не уступает Semantic Scholar и позволяет получать сведения о публикациях, авторах, цитируемости и площадках публикации. При этом ресурс накладывает более строгие ограничения на скорость и объём загрузки данных, поэтому обработка полного корпуса заняла несколько недель.

Полученные данные были сопоставлены с исходными публикациями по DOI. Это позволило объединить тематическую информацию, полученную на этапе поиска, с библиографическими характеристиками, необходимыми для дальнейшего построения графов цитирования и авторства. На основе собранного корпуса был проведён статистический анализ публикационной активности, результаты которого приведены ниже.




Рис. 6: Распределение числа собранных публикаций по годам

На рис. 6 виден рост числа публикаций в 2020–2021 годах, который связан с глобальным всплеском исследований в области машинного обучения и появлением первых трансформерных архитектур, требующих значительных вычислительных ресурсов. Дальнейшее снижение в 2023–2024 годах является естественной нормализацией публикационной активности.




Рис. 7: Количество публикаций по тематике глубокого обучения и трансформеров (бар-плот)

Для доказательства данного заявления проведён анализ числа работ по трансформерам. Результат, представленный на рис. 7 показывает значительную корреляцию между их ростом и общим увеличением публикационной активности в рассматриваемый период. Пик публикаций по данному направлению в 2020–2022 годах, а также последующее снижение к средним значениям совпадают с динамикой, наблюдаемой в общем корпусе работ.




Рис. 8: Распределение публикаций по типам площадок

Большинство публикаций (более 260 тысяч), судя по статистике на рис.8, относится к журнальному формату. Доля трудов с конференций и материалов других типов значительно ниже (менее одного процента). Следовательно, основным источником данных для анализа являются журнальные статьи.

Площадка	Количество статей
The Astrophysical Journal	16102
Monthly Notices of the Royal Astronomical Society	15077
Astronomy and Astrophysics	12522
Physical Review Letters	9300
Physical Review D	7594
Physical Review B	6794
Journal of High Energy Physics	6486
Physical Review E	4425
The Journal of Chemical Physics	3953
Physics Letters B	3690
Physical Review A	3488
Journal of Cosmology and Astroparticle Physics	2839
The European Physical Journal C	2740
The Astrophysical Journal Letters	2058
Journal of Computational Physics	1869
Physical Review C	1826

Таблица 2: Самые крупные журналы по числу публикаций

Таблица 2 показывает, что крупные площадки в выборке представлены журналами по астрофизике, физике высоких энергий и смежным фундаментальным дисциплинам.

Конференция	Количество статей
Proceedings of the AAAI Conference on Artificial Intelligence	160
Proceedings of the Genetic and Evolutionary Computation Conference	84
Proceedings of 37th International Cosmic Ray Conference — PoS(ICRC2021)	49
Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining	49
Proceedings of the 30th ACM International Conference on Multimedia	45
Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval	33
Proceedings of the Genetic and Evolutionary Computation Conference Companion	33
Proceedings of the 31st ACM International Conference on Information & Knowledge Management	32
Proceedings of the ACM Web Conference 2022	31
2022 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)	26
Interspeech 2022	25
2021 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)	22
IOP Conference Series Materials Science and Engineering	21

Таблица 3: Самые крупные сборники трудов конференций по числу публикаций

Анализ конференционных площадок (таблица 3) показал, что наибольшее количество работ приходится на конференции, связанные с искусственным интеллектом, обработкой данных и информационным поиском.




Рис. 9: Распределение числа цитирований




Рис. 10: Распределение числа цитирований среди высокоцитируемых статей (более 500 цитирований)

Распределение числа цитирований публикаций представлено на рисунках 9 и 10. На рисунке 9 показано общее распределение цитирований для всего корпуса публикаций. Основная часть статей имеет сравнительно небольшое число цитирований: менее 50.

При этом с ростом числа цитирований количество соответствующих публикаций быстро уменьшается.

На рисунке 10 отдельно показано распределение среди высокоцитируемых публикаций. Можно заметить, что статьи с числом цитирований более 500 встречаются существенно реже. Несмотря на их небольшую долю в общем корпусе, именно такие работы формируют значительную часть наиболее заметных и влиятельных исследований в области высокопроизводительных вычислений.




Рис. 11: Топ-20 наиболее популярных тегов

Анализ тегов arXiv показывает, что в выборке доминируют направления, связанные с оптимизацией производительности и численным моделированием. Наиболее распространённые теги — vectorization, profiling, numerical simulation и accelerator, что отра-

жает фокус работ на повышении эффективности вычислений, работе с ускорителями и развитии различных параллельных методов.

9.3 Обучение модели SPECTER




Рис. 12: Изменение значения функции потерь при обучении модели на НРС-корпусе




Рис. 13: Изменение значения функции потерь при дополнительном дообучении модели на графе авторства

Для анализа процесса обучения модели были рассмотрены изменения значения функции потерь на различных этапах дообучения модели SPECTER. На рисунке 12 представлена динамика функции потерь при обучении модели на специализированном НРС-корпусе с использованием графа цитирования. На рисунке 13 показан процесс дополнительного дообучения модели с использованием графа авторства. В обоих случаях наблюдается устойчивое уменьшение значения функции потерь по мере обучения модели. На первом этапе значение loss уменьшается приблизительно с 241.6 до 9.36, что соответствует снижению более чем в 25 раз. На этапе дополнительного обучения на графе авторства значение функции потерь уменьшается с 30.8 до 3.05, то есть более чем в 10 раз. Обучение на каждом из этапов проводилось в течение 36 тысяч шагов оптимизации. Наиболее резкое снижение функции потерь наблюдается на начальных этапах обучения, после чего кривая постепенно выходит на плато. Такое поведение свидетельствует о стабильной сходимости модели и отсутствии признаков расходимости процесса оптимизации. Полученные результаты показывают, что использование дополнительного графа авторства позволяет продолжить адаптацию эмбедингов научных

публикаций без разрушения ранее сформированных семантических связей, полученных на этапе обучения на графе цитирования.

9.4 Оценка качества векторных представлений

Для оценки влияния дополнительного графа авторства было выполнено сравнение качества модели до и после второго этапа дообучения. Используемая методика оценки приведена в разделе 7.

В таблице 4 приведены значения метрик для модели, обученной только на графе цитирования, и модели, дополнительно дообученной с использованием графа авторства. Расшифровка метрик также приведена в разделе 7.

Метрика	CG	CG + AG	Изменение
MAG F1	80.1	80.5	+0.4
MeSH F1	83.1	83.1	+0.0
Co-view MAP	83.7	84.7	+1.0
Co-view NDCG	91.1	92.8	+1.7
Co-read MAP	82.7	81.0	-1.7
Co-read NDCG	91.5	92.3	+0.8
Cite MAP	91.2	94.5	+3.3
Cite NDCG	95.6	94.2	-1.4
Co-cite MAP	88.9	89.4	+0.5
Co-cite NDCG	95.7	95.5	-0.2
Recomm $\widehat{NDCG}$	51.6	66.9	+15.3
Recomm $\widehat{P@1}$	20.9	23.6	+2.7

Таблица 4: Сравнение качества модели до и после добавления графа авторства




Рис. 14: Сравнение основных метрик качества представлений




Рис. 15: Сравнение рекомендательных метрик: звёздочкой отмечены скорректированные по позиционному смещению метрики

Добавление графа авторства (см. рис. 14-15) привело к наиболее заметному росту качества на рекомендательных метриках: значение $\widehat{\text{Recomm NDCG}}$ увеличилось с 51.6 до 66.9, а $\widehat{\text{Recomm P@1}}$ — с 20.9 до 23.6. Также наблюдается улучшение по метрикам

Cite MAP, Co-view MAP, Co-view NDCG и Co-read NDCG. Это показывает, что информация об авторских связях усиливает способность модели находить релевантные публикации и улучшает качество ранжирования в задачах рекомендаций. При этом по отдельным метрикам наблюдается небольшое снижение, что указывает на различие между цитатными и авторскими связями: дополнительный граф улучшает не все типы семантической близости одинаково.

Дополнительно была проведена оценка качества модели на сформированном корпусе публикаций по тематике высокопроизводительных вычислений (результаты см. в таблице 5). В эксперимент были включены классификационные метрики MAG F1 и MeSH F1, метрики предсказания прямых цитирований Cite MAP и Cite NDCG. Причины использования сокращённого набора метрик описаны в разделе 7.

Метрика	CG	CG + AG	Изменение
MAG F1	90.1	92.4	+2.3
MeSH F1	90.5	97.2	+6.7
Cite MAP	87.9	87.2	-0.7
Cite NDCG	91.8	92.1	+0.3

Таблица 5: Сравнение качества модели на специализированном корпусе HPC




Рис. 16: Сравнение основных метрик на специализированном корпусе HPC

На специализированном корпусе HPC добавление графа авторства также приводит

к росту большинства метрик (см. рис. 16). Наиболее заметное улучшение наблюдается для MeSH F1 (+6.7), что указывает на положительное влияние авторских связей на тематическую согласованность представлений. Значение Cite MAP немного снижается (-0.7), однако Cite NDCG увеличивается на 0.3. Это означает, что добавление графа авторства не обязательно улучшает все аспекты предсказания прямых цитирований, но может улучшать расположение релевантных публикаций в ранжированном списке.

9.5 Работа рекомендательной модели

Архитектура рекомендательного модуля описана в разделе 8. В практической реализации для ранжирования используются признаки, вычисляемые по названию и аннотации публикации. Для каждой исходной статьи строится эмбединг, после чего он сравнивается с векторными представлениями остальных публикаций корпуса. Дополнительно учитывается лексическое совпадение токенов в названиях и аннотациях.

Оценка релевантности кандидата определяется близостью этих представлений. Публикации сортируются по убыванию этой оценки.

Помимо расчёта формальных метрик была проведена качественная проверка рекомендательной модели на отдельных запросах.

В таблице 6 представлен пример для статьи о производительности RISC-V Vector Extension на задачах HPC и машинного обучения.

№	Ближайшая публикация
1	Ara: A 1 GHz+ Scalable and Energy-Efficient RISC-V Vector Processor with Multi-Precision Floating Point Support in 22 nm FD-SOI
2	PULP-NN: Accelerating Quantized Neural Networks on Parallel Ultra-Low-Power RISC-V Processors
3	The ARM Scalable Vector Extension
4	Design and optimization of a portable LQCD Monte Carlo code using OpenACC
5	The Cost of Application-Class Processing: Energy and Performance Analysis of a Linux-ready 1.7GHz 64bit RISC-V Core in 22nm FDSOI Technology

Таблица 6: Ближайшие публикации для статьи “Closer in the Gap: Towards Portable Performance on RISC-V Vector Processors”

В таблице 7 приведены конференции, рекомендованные для той же исходной публикации.

№	Подходящая конференция
1	MICRO (IEEE/ACM International Symposium on Microarchitecture)
2	HPCA (IEEE International Symposium on High-Performance Computer Architecture)
3	PACT (International Conference on Parallel Architectures and Compilation Techniques)
4	CGO (IEEE/ACM International Symposium on Code Generation and Optimization)
5	CCGrid (IEEE/ACM International Symposium on Cluster, Cloud and Internet Computing)

Таблица 7: Подходящие конференции для статьи “Closer in the Gap: Towards Portable Performance on RISC-V Vector Processors”

Все найденные работы связаны с векторными расширениями, RISC-V, переносимостью производительности и энергоэффективностью процессорных архитектур. Совпадение наблюдается не только на уровне отдельных терминов, но и на уровне технической постановки: в выдаче присутствуют работы о векторных ISA, RISC-V-ядрах, компиляторной поддержке и переносимости HPC-кода. Рекомендованные конференции соответствуют этому профилю: MICRO, HPCA и PACT относятся к архитектуре процессоров и параллельным архитектурам, а CGO покрывает часть работы, связанную с компиляторами и автовекторизацией.

Дополнительно была проведена качественная проверка рекомендаций с использованием LLM-ассистированной оценки. Такая проверка не заменяет экспертную разметку специалистами предметной области, однако позволяет предварительно оценить тематическую согласованность рекомендаций. В качестве эксперта выбрана большая языковая модель ChatGPT⁹. В эксперимент были включены 50 публикаций из HPC-корпуса, относящихся к различным направлениям высокопроизводительных вычислений: распределённые системы, отказоустойчивость, GPU-вычисления, large language models, federated learning, RISC-V, HPC-сети, параллельные архитектуры и оптимизация вычислений.

Для каждой исходной публикации модель формировала пять наиболее близких публикаций и список рекомендуемых конференций.

⁹<https://chatgpt.com/>

Далее проводилась полуавтоматическая экспертная оценка качества рекомендаций. Для анализа использовались названия публикаций, их аннотации, а также рекомендованные конференции. Оценка выполнялась по следующим критериям:

1. тематическое совпадение предметной области;
2. совпадение используемых методов и вычислительных архитектур;
3. совпадение прикладной постановки задачи;
4. соответствие рекомендованных конференций тематике статьи.

Для публикаций и конференций использовалась пятибалльная шкала:

- 5 — полностью релевантная рекомендация;
- 4 — высокая тематическая близость;
- 3 — частичное совпадение тематики;
- 2 — слабая тематическая связь;
- 1 — нерелевантная рекомендация.

Для каждой исходной статьи вычислялись:

- средняя оценка пяти рекомендованных публикаций;
- средняя оценка рекомендованных конференций.

Развёрнутые итоговые оценки представлены в приложении. Средняя оценка релевантности рекомендованных публикаций составила 4.01 из 5, а средняя оценка рекомендованных конференций — 4.46 из 5. Полученные значения указывают на тематическую согласованность рекомендаций в рамках проведённой LLM проверки. При этом результаты следует рассматривать как предварительные до появления полноценного размеченного специалистами в области НРС датасета.

10 Заключение

В рамках выпускной квалификационной работы была разработана и экспериментально проверена рекомендательная система для поиска релевантных научных публикаций и площадок в области высокопроизводительных вычислений. Основные результаты работы можно сформулировать следующим образом:

1. Сформирован и обогащён корпус научных публикаций в области НРС. Были собраны библиографические метаданные, сведения о цитированиях, авторах, площадках публикации и тематических признаках работ.
2. Построены графы цитирования и авторства, которые использовались для формирования обучающих примеров и дообучения модели представлений научных публикаций.
3. Реализована двухэтапная схема дообучения модели эмбедингов: сначала на связях цитирования, затем на связях авторства. Такой подход позволил учитывать как содержательную близость публикаций, так и дополнительные связи между научными коллективами.
4. Экспериментально показано, что добавление графа авторства улучшает качество рекомендаций. Наиболее заметный прирост был получен по рекомендательным метрикам, включая $\text{Recomm } \widehat{\text{NDCG}}$ и $\text{Recomm } \widehat{P@1}$.
5. Реализована модель ранжирования публикаций по текстовому запросу. Она позволяет сопоставлять описание новой статьи с корпусом ранее опубликованных работ и формировать список наиболее близких публикаций.
6. Полученная система формирует ранжированный список релевантных публикаций и рекомендуемых научных площадок. Это позволяет использовать её не только для поиска литературы, но и как вспомогательный инструмент при выборе конференции или журнала для публикации результатов исследования.

Таким образом, поставленная цель работы была достигнута: разработан метод и программная реализация рекомендательной системы, использующей текстовые представления, граф цитирования и граф авторства для поиска релевантных научных пуб-

ликаций в области НРС. Полученные результаты показывают, что использование авторских связей дополняет цитатную информацию и повышает качество рекомендаций, особенно в задачах ранжирования тематически близких публикаций.

11 Литература

- Mikolov, T., Chen, K., Corrado, G., Dean, J. *Efficient Estimation of Word Representations in Vector Space*, arXiv:1301.3781, 2013.
- Devlin, J., Chang, M.-W., Lee, K., Toutanova, K. *BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding*, arXiv:1810.04805, 2019.
- Beltagy, I., Lo, K., Cohan, A. *SciBERT: A Pretrained Language Model for Scientific Text*, arXiv:1903.10676, 2019.
- Cohan, A., Feldman, S., Beltagy, I., Downey, D., Weld, D. S. *SPECTER: Document-level Representation Learning using Citation-informed Transformers*, arXiv:2004.07180, 2020.
- Singh, A., D'Arcy, M., Cohan, A., Downey, D., Feldman, S. *SciRepEval: A Multi-Format Benchmark for Scientific Document Representations*, arXiv:2211.13308, 2022.
- Priem, J., Piwowar, H. A., Orr, R. *OpenAlex: A fully-open index of scholarly works, authors, venues, institutions, and concepts*, arXiv:2205.01833, 2022.

12 Приложение 1

В данном приложении приведён полный список ключевых слов, использованных для тематического поиска статей в области высокопроизводительных вычислений.

HPC, high performance computing, supercomputer, supercomputing, parallel computing, distributed computing, cluster computing, massively parallel, parallel algorithms, parallel processing, scientific computing, high performance system, compute-intensive, GPU computing, GPU acceleration, GPGPU, CUDA, CUDA kernel, CUDA optimization, NVIDIA GPU, tensor cores, GPU cluster, GPU parallel, multi-GPU, heterogeneous computing, accelerator, hardware acceleration, OpenCL, ROCm, AMD GPU, MPI, Message Passing Interface, OpenMP, OpenACC, PGAS, UPC, UPC++, Coarray Fortran, distributed memory, shared memory parallel, hybrid parallelization, CPU cluster, manycore, multicore, vectorization, SIMD, AVX, Xeon Phi, BlueGene, Cray, Fugaku, Frontier supercomputer, Summit supercomputer, exascale, exascale computing, exascale architecture, BLAS, LAPACK, ScaLAPACK, PETSc, Trilinos, OpenBLAS, cuBLAS, cuDNN, FFT, distributed FFT, parallel linear algebra, distributed training, data parallel, model parallel, pipeline parallel, deep learning at scale, large-scale training, GPU clusters for training, HPC for machine learning, HPC for AI, mixed precision, Horovod, DeepSpeed, Megatron, HPC cloud, cloud supercomputer, cloud GPU cluster, virtual cluster, HPC workload, batch scheduling, Slurm, PBS, job scheduler, performance tuning, auto-tuning, code optimization, profiling, parallel efficiency, scalability, strong scaling, weak scaling, performance portability, Kokkos, RAJA, numerical simulation, finite element, finite difference, lattice Boltzmann, molecular dynamics, computational fluid dynamics, CFD, climate modeling, weather simulation, particle-in-cell, monte carlo simulation, high-speed interconnect, Infiniband, RDMA, parallel filesystem, Lustre filesystem, BeeGFS, distributed storage, fault tolerance, checkpointing, energy-efficient computing, HPC scheduling

13 Приложение 2

В приложении 2 приведены результаты оценки рекомендательной модели.

Исходная статья	Публикации	Конференции
Closer in the Gap: Towards Portable Performance on RISC-V Vector Processors	4.7	4.9
An Uncertainty-Aware Resilience Micro-Agent for Causal Observability in the Computing Continuum	3.6	4.5
Surviving Partial Rank Failures in Wide Expert-Parallel MoE Inference	2.8	4.2
Accelerating Compound LLM Training Workloads with Maestro	3.9	4.7
Privacy-preserving Chunk Scheduling in a BitTorrent Implementation of Federated Learning	4.6	4.5
HiRL: Hierarchical Reinforcement Learning for Coordinated Resource Management	3.4	4.2
FractalSortCPU: Bandwidth-Efficient Compressed Radix Sort on CPU	3.5	4.1
Amortized Asynchronous Byzantine Reliable Broadcast with Optimal Resilience	4.5	4.8
Edge-Cloud Collaborative Pothole Detection via Onboard Event Screening and Federated Learning	4.1	4.5
Lakestream: A Consistent and Brokerless Data Plane for Large Foundation Model Training	3.0	4.6
Adaptive Tensor Placement for Multi-GPU Transformer Inference	4.2	4.7
NUMA-Aware Scheduling for Distributed Deep Learning	4.1	4.4
A Hybrid MPI-CUDA Framework for Sparse Matrix Computation	4.3	4.6
Distributed Checkpoint Recovery in Exascale Systems	4.0	4.7

Performance Portability for Heterogeneous HPC Clusters	4.2	4.5
Topology-Aware Collective Communication for GPU Clusters	4.4	4.8
Efficient KV-Cache Synchronization for LLM Serving	3.7	4.5
Federated Optimization under Network Heterogeneity	4.3	4.4
GPU-Accelerated Molecular Dynamics with Dynamic Load Balancing	4.1	4.6
Elastic Resource Allocation for Edge AI Systems	3.5	4.1
Parallel Graph Processing using RDMA Interconnects	4.2	4.5
Communication-Avoiding Krylov Solvers for HPC Applications	4.5	4.7
Scalable Training of Mixture-of-Experts Models on GPU Superclusters	3.6	4.6
Dynamic Batch Scheduling for Multimodal LLM Pipelines	3.4	4.5
Fault-Tolerant Distributed Storage for Scientific Workloads	4.0	4.4
Compiler Optimizations for Vectorized Scientific Kernels	4.6	4.8
Energy-Efficient Parallel Computing on ARM Architectures	4.3	4.5
Distributed Reinforcement Learning with GPU Parameter Servers	3.9	4.3
Bandwidth-Aware Expert Routing for Sparse LLM Inference	3.5	4.6
Portable OpenACC Optimizations for Climate Simulation Codes	4.4	4.7
Adaptive Runtime for HPC Workflow Scheduling	4.0	4.4

Efficient Tensor Parallelism for Transformer Inference	4.1	4.7
Scalable Federated Learning on Edge GPU Devices	4.5	4.4
Byzantine-Resilient Consensus for Distributed GPU Systems	4.2	4.7
Heterogeneous Cluster Scheduling using Deep Reinforcement Learning	3.6	4.2
GPU Memory Compression for Large-Scale Training	3.8	4.6
RDMA-Optimized Communication for Distributed Deep Learning	4.4	4.8
Load-Balanced Sparse Attention for Foundation Models	3.5	4.5
Fault-Tolerant Collective Operations in Exascale Computing	4.3	4.7
Asynchronous Pipeline Parallelism for LLM Training	3.9	4.6
Multi-Agent Resource Coordination in HPC Clouds	3.7	4.2
Parallel I/O Optimization for Scientific Data Pipelines	4.2	4.5
Energy-Aware Scheduling in GPU Supercomputers	4.0	4.4
Scalable Distributed Embedding Systems for Recommendation Models	3.8	4.3
Efficient Sparse Communication for MoE Training	3.6	4.6
Topology-Aware Placement of Large AI Models	3.7	4.5
GPU Cluster Virtualization for Scientific Computing	4.0	4.4
Resilient Runtime Systems for Distributed AI Workloads	4.1	4.6
Compiler-Assisted Optimization for Tensor Kernels	4.5	4.7
Adaptive Parallelization Strategies for Scientific Simulations	4.3	4.5
Среднее значение	4.01	4.46